Innovación en Transporte y Huella Urbana en Zonas de Riesgo: Análisis Causal de Transmicable en Ciudad Bolívar

Juan Esteban Segura

3 de diciembre de 2024

Resumen

Este artículo evalúa el impacto de las innovaciones en transporte, con énfasis en el TransMiCable de Ciudad Bolívar, sobre los patrones de urbanización en áreas marginadas de Bogotá. Utilizando un enfoque de Diferencias en Diferencias (DiD) combinado con análisis de eventos, se examina el crecimiento urbano y la ocupación de terrenos en zonas de riesgo geográfico. Utilizando imágenes satelitales y técnicas de machine learning, se construye una base de datos para rastrear la evolución espacial. Los hallazgos muestran un incremento en la ocupación de terrenos de riesgo geográfico y en la densidad urbana en las áreas adyacentes a las estaciones de TransMiCable.

Palabras clave: Transporte urbano, Innovación en infraestructura, Riesgo geográfico, Dinámica urbana, Diferencias en Diferencias, Bogotá, Ciudad Bolívar, Machine learning.
Clasificación JEL: O18, R42, C21, R12, C55.

1. Introducción

Las innovaciones en infraestructura de transporte han transformado los paisajes urbanos, especialmente en ciudades de economías emergentes. Estas intervenciones son clave para mejorar la accesibilidad y la conectividad urbana, promoviendo la integración social y económica de áreas periféricas (Gibbons et al., 2012). Un ejemplo destacado es el *TransMiCable* en Bogotá, un sistema de transporte aéreo diseñado para conectar zonas marginadas con el resto de la ciudad. La primera línea, inaugurada en diciembre de 2018, conecta el sector de El Paraíso con el Portal Tunal en Ciudad Bolívar, beneficiando a más de 700.000 habitantes mediante la reducción de tiempos de viaje y costos de transporte (Alcaldía Bogotá, 2023).

En 2023, se anunciaron dos nuevas líneas: una en la localidad de San Cristóbal y otra proyectada para Potosí, también en Ciudad Bolívar pero con afectaciones en barrios de la localidad de Soacha. Estas expansiones planean extender la cobertura del sistema a más de un millón de habitantes (Tiempo, 2023). Aunque estas intervenciones buscan mejorar la movilidad urbana y fomentar el desarrollo económico (Duranton and Turner, 2012), su impacto sobre los patrones de urbanización y la ocupación del suelo ha recibido menos atención en la literatura.

Este estudio se enfoca en un fenómeno emergente asociado con el TransMiCable: el incremento en la ocupación de terrenos inestables y previamente inaccesibles. Evidencias obtenidas de imágenes satelitales sugieren dos dinámicas principales. Primero, un efecto intensivo, caracterizado por el aumento en la densidad poblacional en áreas cercanas a la infraestructura (ver Figura 1). Segundo, un efecto extensivo, reflejado en la expansión hacia zonas previamente desocupadas (ver Figura 2), incluidas áreas con altos niveles de riesgo geográfico (ver Figura 3). Para enmarcar este análisis, se adopta la definición de riesgo geográfico del Instituto Geográfico Agustín Codazzi (IGAC), que asocia el riesgo con la susceptibilidad a deslizamientos de tierra según la pendiente del terreno, siendo aquellas superiores al 30 % particularmente propensas a derrumbes (Instituto Geográfico Agustín Codazzi, 2020).

Estos patrones plantean preguntas sobre cómo estas innovaciones influyen en la urbanización no planificada y las implicaciones de la expansión hacia áreas de alto riesgo. Para responder a estas preguntas, el objetivo principal de esta investigación es analizar cómo la infraestructura de transporte, específicamente el TransMiCable, afecta la distribución de la población en estas áreas.

En contextos urbanos vulnerables, las trampas de pobreza desempeñan un papel central en la persistencia de condiciones de marginalidad (Bowles et al., 2006). Estas trampas, alimentadas por la falta de acceso a infraestructura básica, limitan las oportunidades de movilidad social. Las intervenciones como el TransMiCable buscan romper estas dinámicas al conectar áreas periféricas con el tejido urbano. Sin embargo, estas soluciones pueden generar efectos no deseados, como la consolidación de asentamientos en terrenos geográficamente desfavorables, exacerbando la vulnerabilidad de estas comunidades. Este fenómeno abre la discusión sobre la idoneidad de intervenciones exclusivamente infraestructurales en áreas de alto riesgo. En algunos casos, podría ser más efectivo considerar estrategias de reubicación planificada, dado que muchas de estas áreas presentan características económicas y geográficas que limitan su desarrollo sostenible (Krishna, 2010).

La literatura económica ha documentado ampliamente los beneficios de las innovaciones en infraestructura de transporte en contextos urbanos de países en desarrollo. Ejemplos como el Metrocable de Medellín muestran mejoras en la calidad de vida derivadas de la reducción de tiempos de viaje y costos (Brand and Dávila, 2011). Sin embargo, estudios recientes han comenzado a examinar los efectos no deseados de estas infraestructuras, como el aumento en asentamientos informales en áreas geográficamente vulnerables. En Medellín, la expansión de la Línea H del Metrocable mostró que, si bien se redujo la informalidad en ciertas zonas, también se incrementó la ocupación de terrenos inestables (Dávila, 2013). Este fenómeno se atribuye a la mejora en conectividad, que genera incentivos para la ocupación de áreas previamente deshabitadas.

A pesar de los avances en la literatura, la capacidad de estimar los efectos negativos de infraestructuras de transporte enfrenta limitaciones metodológicas significativas. Muchos estudios se basan en análisis observacionales que no logran establecer relaciones causales claras debido a la falta de datos detallados y la dificultad para construir contrafactuales creíbles. Este trabajo busca superar estas limitaciones mediante dos innovaciones metodológicas. En primer lugar, se construye una base de datos inédita que combina imágenes satelitales con técnicas de machine learning para rastrear la evolución de edificaciones en áreas de interés. La literatura reciente demuestra un creciente uso de estas técnicas en economía urbana, destacando su efectividad para el conteo de edificaciones, la detección de características urbanas y la generación de datos precisos en estudios de expansión urbana (Arribas-Bel et al., 2021, Li, 2021, Volpi and Tuia, 2016, Aytekin and Uysal, 2018). Estas metodologías han sido utilizadas en contextos similares para monitorear cambios urbanos no planificados y evaluar políticas en áreas vulnerables, marcando una tendencia hacia

enfoques más robustos y basados en datos.

En segundo lugar, se aprovecha el anuncio de dos nuevas líneas de TransMiCable (San Cristóbal y Potosí) como un contrafactual natural, bajo el supuesto de que estas áreas comparten características observables y no observables que las hacen comparables. La literatura reciente en inferencia causal proporciona herramientas valiosas para abordar estos desafíos. Por ejemplo, Vasquez-Bare (2022) analiza efectos de spillover utilizando variables instrumentales, mientras que Pollman (2022) y Butts (2024) desarrollan enfoques para modelar interferencias espaciales y descomponer sesgos en estimaciones causales. Sin embargo, estos métodos enfrentan limitaciones en contextos urbanos densamente conectados, como Ciudad Bolívar, donde los efectos de spillover pueden ser amplios y difíciles de delimitar.

En la actualidad, los resultados preliminares de este estudio muestran efectos mixtos. Se observa un incremento en la densidad poblacional en zonas cercanas al TransMiCable, a una velocidad significativamente mayor que en los contrafactuales, indicando un efecto intensivo. Además, existe un efecto extensivo, evidenciado por la ocupación de nuevas zonas con características geográficas de riesgo. Estos hallazgos refuerzan la necesidad de evaluar los impactos no intencionados de la infraestructura en áreas vulnerables, especialmente en contextos de urbanización no planificada. No obstante, los resultados actuales están condicionados por la calidad de las imágenes satelitales y las limitaciones de los modelos de conteo lo cual genera un reto importante.

2. Datos

El análisis se realizó sobre una muestra geográfica de **366.5 km²**, que incluye las localidades de *Ciudad Bolívar* (130 km²), *San Cristóbal* (49.5 km²) y *Soacha* (187 km²)[1]. Las imágenes satelitales se obtuvieron mediante procesos automatizados de *Google Earth Pro* y se procesaron utilizando la API de *Google Earth Engine* (Gorelick et al., 2017). Para un análisis espacial uniforme, el área de estudio fue segmentada en bloques regulares de **100 m x 100 m**, siguiendo enfoques previamente validados (Shah et al., 2018), resultando en un total de **37,982 polígonos**.

Las imágenes recopiladas abarcan el período 2010-2022, divididas en fases pre-intervención (2010-2015), construcción (2016-2018) y post-intervención (2019-2022). Este período finaliza en septiembre de 2022, coincidiendo con el anuncio de las nuevas líneas de TransMiCable, lo que evita posibles efectos anticipados en el análisis. La selección de imágenes priorizó

[1]La localidad de Soacha será impactada por la futura línea de TransMiCable en el sector de Potosí.

aquellas con menor nubosidad; en casos de condiciones adversas, se incluyeron capturas redundantes tomadas en días consecutivos[2]. No obstante, no se dispone de datos para 2011, 2014 y 2017 debido a limitaciones en los pasos de los satélites *Maxar* y *CNES/Airbus*.

El Cuadro 1 resume el número de polígonos y fotografías disponibles por localidad. Ciudad Bolívar incluye **13,460 polígonos** y **134,600 fotos**, siendo el área principal del estudio por su relación con la primera línea de TransMiCable. San Cristóbal comprende **5,152 polígonos** y **51,520 fotos**, mientras que Soacha, con mayor extensión, abarca **19,370 polígonos** y **193,700 fotos**. En total, se analizaron **379,820 imágenes**, lo que proporciona una base sólida para evaluar cambios espaciales.

El Cuadro 2 detalla la disponibilidad de imágenes por año, indicando el mes correspondiente y su contexto (pre, construcción o post). La mayoría de las imágenes corresponden a enero y febrero, con excepciones en 2020 y 2022, cuando se capturaron en marzo y mayo, respectivamente. Este registro asegura una continuidad en el seguimiento temporal, permitiendo una comparación consistente de las dinámicas urbanas.

Asi mismo, el esquema en la Figura 5 sintetiza el proceso completo de recopilación y procesamiento de datos, desde la extracción inicial hasta el almacenamiento estructurado de imágenes y características extraídas. Este flujo incluye herramientas y metodologías utilizadas.

Cuadro 1. Número de polígonos, fotos disponibles y período de análisis por localidad

Localidad	**Número de polígonos (i)**	**Fotos disponibles**	**Período disponible**
Ciudad Bolívar	13,460	134,600	10 años
San Cristóbal	5,152	51,520	10 años
Soacha	19,370	193,700	10 años
Total	**37,982**	**379,820**	**-**

2.1. Extracción de Información de Líneas de TransMiCable

En terminos de informacion de transmicable fundamental para el estudio se recopiló información detallada sobre las líneas actuales y proyectadas del sistema. Esta información incluye la ubicación de estaciones, torres (pilones), trayectos y avances de construcción.

[2]La redundancia en las capturas asegura datos confiables al reducir los efectos de la nubosidad.

Los datos se obtuvieron de documentos oficiales del Instituto de Desarrollo Urbano (IDU), la Alcaldía Mayor de Bogotá y la Contraloría.

Por ejemplo, el contrato de consultoría No. 1630 de 2020 del IDU detalla los estudios y diseños del cable aéreo en San Cristóbal, proporcionando coordenadas precisas de las estaciones y pilones planificados (Instituto de Desarrollo Urbano (IDU), 2020). Adicionalmente, informes de la Alcaldía y la Contraloría ofrecen estimaciones sobre el progreso de las obras y proyecciones de expansión (Alcaldía Mayor de Bogotá, 2023, Contraloría Distrital de Bogotá, 2022). Esta información fue esencial para evaluar la proximidad de las construcciones a las comunidades afectadas y para analizar los cambios en la ocupación del suelo en relación con la infraestructura del TransMiCable.

2.2. Fuentes y Características de las Imágenes Satelitales

Las imágenes utilizadas provienen de *CNES/Airbus*, *Landsat*, y *Maxar Technologies*. Las imágenes de *Landsat* 7 y 8, con una resolución de **30 m/píxel**, abarcan datos desde 2001 (Wulder et al., 2012, Roy et al., 2014), y se emplearon para análisis de cambios a gran escala. Por su parte, las imágenes de alta resolución (**0.31-0.50 m/píxel**) provenientes de *Maxar Technologies* (satélites *WorldView 3* y *WorldView 4*) permitieron identificar detalles urbanos como infraestructuras y áreas verdes (Zhu and Woodcock, 2014, Technologies, 2020).

Para mejorar la calidad y precisión espacial, todas las imágenes fueron sometidas a procesos de ortorrectificación y afinamiento pancromático[3]. Estas técnicas garantizaron la consistencia en los análisis geoespaciales y redujeron distorsiones en las proyecciones originales.

2.3. Extracción de Características Geoespaciales (Covariables)

El estudio utilizó polígonos oficiales obtenidos de la API de Bogotá (OpenDataSoft, 2024) para definir las áreas de interés. Estos polígonos facilitaron la integración de datos geoespaciales de diferentes fuentes. Incorporamos información del Instituto Geográfico Agustín Codazzi (IGAC) y variables generadas mediante Google Earth Engine para enriquecer el análisis.

[3]La ortorrectificación corrige las distorsiones geométricas causadas por la perspectiva del satélite, mientras que el afinamiento pancromático combina imágenes pancromáticas de alta resolución con multiespectrales para mejorar la claridad espacial (Toutin, 2004).

Cuadro 2. Disponibilidad de imágenes satelitales por año y período de análisis.

Año	Disponible	Mes de la foto	Período	Número de fotos
2010	Sí	Enero	Pre	379,820
2011	No	N/A	Pre	0
2012	Sí	Febrero	Pre	379,820
2013	Sí	Enero	Pre	379,820
2014	No	N/A	Pre	0
2015	Sí	Enero	Pre	379,820
2016	Sí	Enero	Construcción	379,820
2017	No	N/A	Construcción	0
2018	Sí	Enero	Construcción	379,820
2019	Sí	Enero	Post	379,820
2020	Sí	Marzo	Post	379,820
2021	Sí	Enero	Post	379,820
2022	Sí	Mayo	Post	379,820

El IGAC proporcionó planchas sísmicas y cartografía detallada. Digitalizamos y alineamos estas capas con los polígonos de análisis (ver Figura 7). Esto permitió derivar variables clave como la ubicación de fallas geológicas y la presencia de zonas de riesgo geográfico, además de calcular la pendiente promedio, minima y maxima a partir de curvas de nivel.

Google Earth Engine se utilizó para generar tres variables específicas: número de parques, número de vías (principales y secundarias) y número de árboles. Estas variables se integraron con los datos proporcionados por el IGAC para construir covariables de cada uno de los poligonos.

Esta metodología permitió evaluar elementos clave como la variación topográfica, la infraestructura vial y la cobertura de zonas verdes en las áreas de interés.

2.4. Creacion de variables dependientes

En términos de la variable dependiente, se definieron dos métricas principales: (1) el número de edificios detectados en cada imagen, y (2) la huella urbana, medida como el

porcentaje de píxeles de una imagen que contienen edificios sobre el número total de píxeles (Krizhevsky et al., 2012, LeCun et al., 2015).

Para generar estas variables, se emplearon dos enfoques principales. El primer enfoque utilizó el proyecto *Open Buildings V3 Polygons* de Google, que proporciona imágenes satelitales junto con el número de edificios detectados como referencia. Este proyecto sirvió como base para entrenar y validar un modelo basado en la arquitectura *U-Net* [4], ampliamente utilizada para segmentación en imágenes geoespaciales (Iatrou et al., 2021, Google, 2021). La *U-Net* permitió segmentar imágenes en regiones urbanas y no urbanas, generando datos clave para el análisis. En la Figura 9, se muestra un ejemplo de segmentación aplicada a un subpolígono.

El segundo enfoque empleó el modelo SAM [5] (*Segment Anything Model*) (Kirillov et al., 2023), que realiza una segmentación inicial en las imágenes (Ver Figurea 7 y 8). Posteriormente, un modelo de clasificación binaria categorizó las máscaras en edificios y no edificios, permitiendo el conteo final de edificaciones en cada imagen. Este enfoque complementó al modelo *U-Net*, especialmente en imágenes con características más complejas.

Ambos modelos mostraron comportamientos diferenciados según el periodo analizado. El modelo *U-Net* mostró un rendimiento más robusto en imágenes posteriores a 2020, beneficiándose de datos de mayor resolución. Sin embargo, presentó limitaciones en imágenes anteriores a 2020. Por otro lado, el modelo SAM superó a *U-Net* en imágenes más antiguas, aunque ambos enfoques resultaron competitivos en periodos más recientes.

Para evaluar el rendimiento de los modelos, se utilizó la métrica de Intersección sobre Unión (IoU), ampliamente aceptada para segmentación (Everingham et al., 2015). Actualmente, el rendimiento promedio del IoU supera el 75 %, aunque presenta variaciones significativas según la localidad. Las imágenes de Soacha mostraron mayores tasas de error debido a la menor calidad de las capturas satelitales, lo que afecta la precisión de los modelos. El Cuadro 3 detalla los rendimientos de ambos enfoques según localidad y periodo. Este rendimiento desigual puede introducir sesgos en los modelos econométricos, particularmente en términos de expansión urbana, llevandonos a falsas conclusiones. Actualmente, se están desarrollando estrategias para mejorar el modelo SAM mediante la incorporación de más ejemplos de entrenamiento, con el objetivo de reducir errores en futuras iteraciones.

[4]La U-Net es una red convolucional diseñada para tareas de segmentación. Se utiliza ampliamente en imágenes médicas y geoespaciales debido a su capacidad para identificar características específicas a nivel de píxeles (Ronneberger et al., 2015).

[5]El modelo SAM (*Segment Anything Model*) es una arquitectura diseñada para segmentación de imágenes de propósito general. Su flexibilidad le permite trabajar con diferentes dominios de imágenes, clasificando áreas de interés automáticamente y generando máscaras de segmentación precisas (Kirillov et al., 2023).

Cuadro 3. Rendimiento de los modelos por localidad, periodo y enfoque (Muestra: 100 polígonos seleccionados al azar)

Localidad	**Enfoque**	**Periodo**	**IoU (%)**
Ciudad Bolívar	U-Net	Pre-intervención (2010-2015)	30.2
Ciudad Bolívar	SAM	Pre-intervención (2010-2015)	75.1
Ciudad Bolívar	U-Net	Construcción (2016-2018)	40.1
Ciudad Bolívar	SAM	Construcción (2016-2018)	80.2
Ciudad Bolívar	U-Net	Post-intervención (2019-2022)	86.9
Ciudad Bolívar	SAM	Post-intervención (2019-2022)	84.3
San Cristóbal	U-Net	Pre-intervención (2010-2015)	31.3
San Cristóbal	SAM	Pre-intervención (2010-2015)	74.1
San Cristóbal	U-Net	Construcción (2016-2018)	39.9
San Cristóbal	SAM	Construcción (2016-2018)	80.1
San Cristóbal	U-Net	Post-intervención (2019-2022)	87.1
San Cristóbal	SAM	Post-intervención (2019-2022)	85.2
Soacha	U-Net	Pre-intervención (2010-2015)	15.1
Soacha	SAM	Pre-intervención (2010-2015)	20.6
Soacha	U-Net	Construcción (2016-2018)	20.9
Soacha	SAM	Construcción (2016-2018)	40.5
Soacha	U-Net	Post-intervención (2019-2022)	30.1
Soacha	SAM	Post-intervención (2019-2022)	40.2

3. Metodología

Este estudio se propone evaluar el impacto del TransMiCable sobre la densidad urbana y la ocupación de terrenos con riesgo geográfico en Bogotá, utilizando un diseño de Diferencias en Diferencias (DiD) (Angrist and Pischke, 2008). Este enfoque permite identificar efectos causales al comparar la evolución de áreas tratadas y de control antes y después de la implementación de la infraestructura. La metodología se desarrolla en tres etapas

principales: la asignación de tratamiento y construcción de contrafactuales, la aplicación de técnicas de *matching* para garantizar la comparabilidad entre grupos, y la especificación de los modelos econométricos utilizados.

3.1. Asignación de Tratamiento y Construcción de Contrafactuales

El primer paso en el diseño empírico es la definición de áreas tratadas y de control. El tratamiento se asigna a bloques dentro de un radio de 1000 metros alrededor de las estaciones operativas del TransMiCable, un umbral que captura razonablemente el área de alta accesibilidad directa asociada con la infraestructura, en línea con trabajos previos sobre el impacto de grandes proyectos de transporte (Duranton and Turner, 2012). Los bloques fuera de este radio, pero cercanos a estaciones planeadas o en construcción, se consideran como el grupo de control. Este diseño aprovecha la similitud inicial entre estas áreas en términos de características geográficas y demográficas, como densidad poblacional, pendiente del terreno y acceso limitado a servicios básicos.

Un aspecto clave de este enfoque es la inclusión de estaciones futuras como parte del grupo de control. Esto permite una mejor comparabilidad, ya que estas áreas presentan condiciones iniciales similares a las tratadas. Además, la separación física entre estaciones operativas y futuras ayuda a mitigar los efectos de *spillovers*, fortaleciendo la validez del supuesto de independencia estable de las unidades ($SUTVA$). Diseños alternativos, como los basados exclusivamente en anillos de influencia (e.g., 1000-2000 metros), fueron descartados debido a limitaciones específicas del contexto urbano, como la alta densidad poblacional y la probabilidad de efectos indirectos del tratamiento en los anillos exteriores.

La Figura 10 ilustra la distribución geográfica de los polígonos tratados y de control en las localidades de Ciudad Bolívar, San Cristóbal y Soacha. Este mapa destaca cómo el diseño combina proximidad geográfica con características comparables, maximizando la validez del análisis.

3.2. Matching como Enfoque Complementario

Para garantizar la comparabilidad entre áreas tratadas y de control, se utiliza un enfoque basado en puntajes de propensión (*propensity score*), una metodología ampliamente empleada en estudios económicos para abordar problemas de selección y estimar efectos causales (Rosenbaum and Rubin, 1983),(Imbens and Rubin, 2015). Este método estima la

Figura 10. Distribución geográfica de polígonos tratados (en verde) y de control (en azul) en Ciudad Bolívar, San Cristóbal y Soacha.

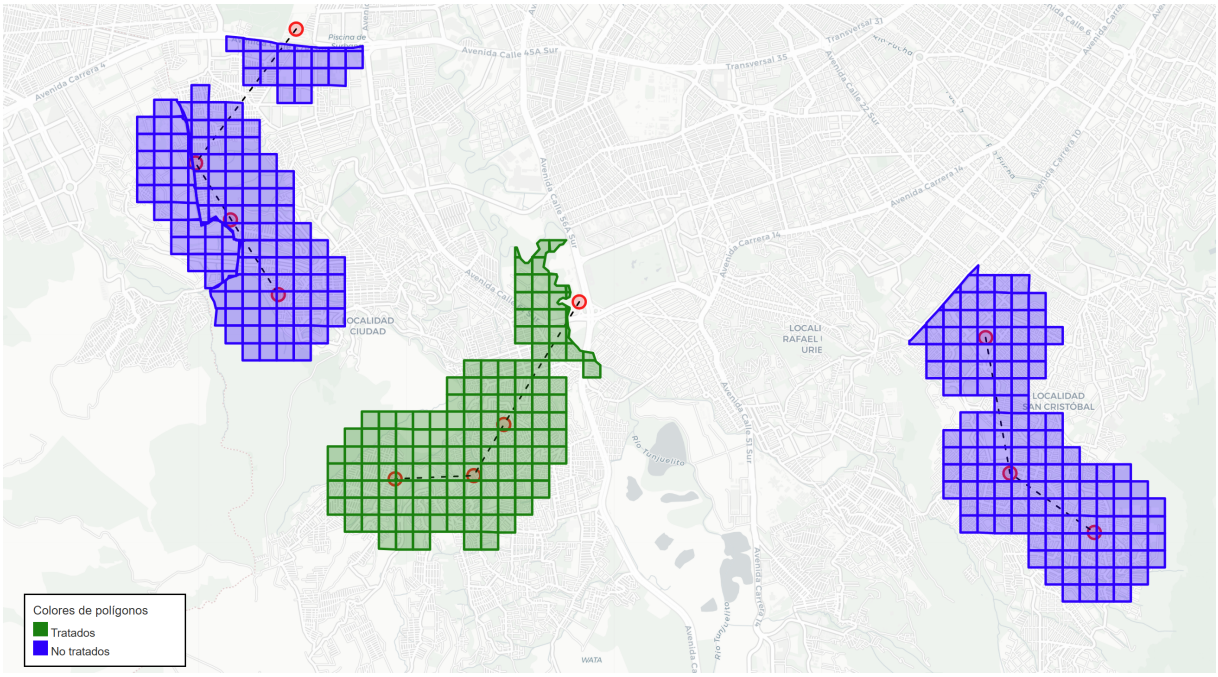

probabilidad de que un bloque sea tratado en función de covariables clave, como densidad urbana inicial, pendiente promedio del terreno, proximidad a vías principales y secundarias, vegetación (parques y árboles) y la presencia de fallas geológicas. Estas características permiten capturar factores relevantes que podrían influir tanto en la probabilidad de tratamiento como en los resultados.

El uso de *propensity score* incluye tanto el *matching* como la ponderación (*weighting*) para garantizar que los bloques de control sean comparables a los tratados en términos de sus características iniciales. Este enfoque no solo permite reducir sesgos en la comparación, sino que también proporciona una herramienta robusta para evaluar la sensibilidad de los resultados bajo diferentes especificaciones. Para garantizar la robustez del análisis, se llevarán a cabo ejercicios con y sin la aplicación de puntajes de propensión, permitiendo evaluar si las diferencias observadas son consistentes independientemente de la técnica utilizada (Hirano et al., 2003).

3.3. Especificación del Modelo Econométrico

El análisis econométrico se desarrolla en dos etapas principales. En la primera, se emplea un modelo base para estimar el impacto promedio del TransMiCable sobre la densidad

urbana en las áreas tratadas. Posteriormente, el análisis se amplía mediante un modelo más profundo que incluye interacciones entre el tratamiento y características geográficas, así como una descomposición de los efectos en distintas fases de implementación.

3.3.1. Modelo Base

El modelo base se fundamenta en un diseño de Diferencias en Diferencias (DiD) para capturar el impacto directo del tratamiento:

$$Y_{i,l,b,t} = \delta_t + \delta_l + \delta_b + \beta_1 \cdot Tratado_{i,t} + \epsilon_{i,l,b,t}$$

Donde:

- $Y_{i,l,b,t}$: Densidad de edificaciones en el bloque i, localidad l, barrio b y tiempo t.
- δ_t, δ_l, δ_b: Efectos fijos de tiempo, localidad y barrio, respectivamente, que controlan por heterogeneidades inobservadas.
- $Tratado_{i,t}$: Dummy que toma el valor de 1 si el bloque i está dentro del radio de influencia del TransMiCable en el tiempo t.
- $\epsilon_{i,l,b,t}$: Término de error idiosincrático.

El parámetro de interés, β_1, mide el cambio promedio en la densidad urbana atribuible al tratamiento.

3.3.2. Modelo Ampliado

Para analizar en profundidad los mecanismos detrás del impacto del TransMiCable, se utiliza un modelo ampliado que incluye interacciones clave y variables temporales específicas de cada fase del proyecto:

$$\begin{aligned} Y_{i,l,b,t} = {} & \beta_0 + \beta_1 \cdot Tratado_{i,t} + \beta_2 \cdot RiesgoGeografico_i + \beta_3 \cdot (Tratado_{i,t} \times RiesgoGeografico_i) \\ & + \beta_4 \cdot PreSinConstruccion_i + \beta_5 \cdot (PreSinConstruccion_i \times Tratado_{i,t}) \\ & + \beta_6 \cdot Anuncio_t + \beta_7 \cdot Construccion_t + \beta_8 \cdot PostOperación_t \\ & + \delta_t + \delta_l + \delta_b + \epsilon_{i,l,b,t} \end{aligned}$$

Donde:

- $RiesgoGeografico_i$: Variable dicotómica que toma el valor de 1 si la pendiente promedio del bloque i es superior al 30 %, siguiendo la definición de riesgo geográfico del Instituto Geográfico Agustín Codazzi (IGAC).
- $(Tratado_{i,t} \times RiesgoGeografico_i)$: Interacción que mide cómo el impacto del tratamiento varía en terrenos clasificados como de alto riesgo geográfico, capturando dinámicas específicas de urbanización en estas áreas.
- $PreSinConstruccion_i$: Indicador para bloques sin construcciones previas.
- $(PreSinConstruccion_i \times Tratado_{i,t})$: Interacción que evalúa la expansión hacia áreas no urbanizadas antes del tratamiento.
- $Anuncio_t$, $Construccion_t$, $PostOperación_t$: Variables temporales que representan las fases del proyecto: anuncio (2015), construcción (2016-2018) y post-operación (2019-2022).
- δ_t, δ_l, δ_b: Efectos fijos de tiempo, localidad y barrio, respectivamente.
- $\epsilon_{i,l,b,t}$: Término de error idiosincrático.

El modelo amplía la comprensión del impacto del TransMiCable al descomponer los efectos en dos dimensiones principales: intensivos y extensivos. Los efectos intensivos, capturados por β_1, reflejan cambios en la densidad urbana dentro de áreas tratadas previamente urbanizadas. Por su parte, los efectos extensivos se miden mediante β_3 y β_5. En particular, $\beta_3 > 0$ indicaría una mayor ocupación de terrenos clasificados como de alto riesgo geográfico debido al TransMiCable. Este coeficiente es fundamental porque aísla el impacto específico de los incentivos generados por la infraestructura sobre la aparición de asentamientos en zonas de riesgo geográfico, diferenciándolo del crecimiento urbano normal capturado por β_2. Así, mientras que β_2 refleja el crecimiento base hacia terrenos de riesgo en ausencia del tratamiento, β_3 identifica el efecto adicional atribuido directamente a la presencia del TransMiCable, constituyendo un pilar clave de la investigación.

Las variables temporales ($Anuncio_t$, $Construccion_t$ y $PostOperación_t$) permiten evaluar los impactos diferenciados de cada fase del proyecto. Un $\beta_6 > 0$ refleja efectos anticipativos tras el anuncio, asociados a expectativas positivas de desarrollo y accesibilidad, que fomentan la construcción de nuevos asentamientos. Durante la fase de construcción, un $\beta_7 < 0$ captura la disminución en la formación de asentamientos informales debido al

incremento en la atención institucional o en la vigilancia, lo que actúa como un mecanismo de control indirecto. Finalmente, un $\beta_8 > 0$ sugiere un aumento en las construcciones post-operación, evidenciando un efecto de consolidación a mediano plazo vinculado a los beneficios de la infraestructura.

Al incorporar interacciones con riesgo geográfico y temporalidad, el modelo permite no solo identificar los efectos del tratamiento, sino también descomponer los mecanismos detrás de los impactos observados en términos de urbanización extensiva e intensiva. Esto proporciona una visión integral del impacto del TransMiCable en contextos de riesgo y vulnerabilidad urbana.

4. Resultados Principales

Los resultados preliminares del modelo general muestran un efecto positivo y estadísticamente significativo del tratamiento (β_1) sobre la densidad urbana en las áreas tratadas, lo que sugiere que la infraestructura del TransMiCable promueve el desarrollo urbano en zonas con mayor accesibilidad, en línea con estudios previos sobre infraestructura y urbanización (Duranton and Turner, 2012, Gibbons et al., 2012).

Sin embargo, estos hallazgos deben tomarse con cautela debido a problemas en la calidad de los datos, particularmente en Soacha, donde se han identificado inconsistencias significativas en el conteo de edificaciones. Estas discrepancias podrían sesgar las estimaciones al atribuir efectos al tratamiento que no reflejan necesariamente impactos reales. Asimismo, las variaciones en la calidad de las imágenes satelitales y la falta de información completa sobre edificaciones previas dificultan una atribución precisa de los cambios observados.

Para abordar estas limitaciones, se están mejorando los modelos de conteo mediante la ampliación de las bases de entrenamiento y validaciones cruzadas con fuentes alternativas, buscando garantizar estimaciones más precisas y robustas.

Dado el carácter preliminar del análisis, no se incluyen resultados numéricos ni tablas de regresión para evitar interpretaciones prematuras. Se prioriza mejorar la calidad de los datos y asegurar que los resultados reflejen con precisión el impacto del TransMiCable en la densidad urbana y la ocupación de terrenos en áreas vulnerables y de riesgo geográfico.

5. Ejercicios de Robustez

Para evaluar la validez de los resultados obtenidos, esta sección presenta una serie de ejercicios de robustez. Estos análisis abordan la suposición de tendencias paralelas, la comparación entre las líneas de TransMiCable, y la variación en distancias y unidades de estudio. La combinación de estos enfoques permite explorar la sensibilidad de los resultados y garantizar la validez de las conclusiones.

5.1. Verificación de la Suposición de Tendencias Paralelas

La suposición de tendencias paralelas entre las localidades tratadas y de control es fundamental para la validez del diseño de este estudio. Dado que la base de datos principal aún está en proceso de finalización, se han utilizado datos preliminares de fuentes como el Departamento Administrativo Nacional de Estadística (DANE), la Secretaría Distrital de Planeación (SDP) y la Gran Encuesta Integrada de Hogares (GEIH) 2010. Estas fuentes permiten evaluar similitudes en variables demográficas y socioeconómicas entre 2010 y 2015.

Las proyecciones del DANE muestran que Ciudad Bolívar y San Cristóbal presentan tasas de crecimiento poblacional cercanas al 2 % durante el período pre-intervención, lo que refleja dinámicas demográficas comparables. Además, la esperanza de vida al nacer es similar: 76.9 años para hombres y 81.6 años para mujeres en Ciudad Bolívar, frente a 76.4 y 80.7 años, respectivamente, en San Cristóbal (Departamento Administrativo Nacional de Estadística (DANE), 2018). La GEIH 2010 reporta ingresos promedio similares en ambas localidades, con una mediana estimada de COP 850,000 en Ciudad Bolívar y COP 870,000 en San Cristóbal (Departamento Administrativo Nacional de Estadística (DANE), 2018).

En cuanto a Soacha, su proximidad geográfica y sus dinámicas demográficas y económicas refuerzan la comparabilidad con Ciudad Bolívar y San Cristóbal. Según el POT de Soacha (2017), este municipio experimentó un crecimiento sostenido en construcción de viviendas y empleo informal, alineándose con las dinámicas observadas en las localidades del sur de Bogotá (Alcaldía Municipal de Soacha, 2017). Estas similitudes respaldan la suposición de tendencias paralelas y la validez de los grupos de comparación.

5.2. Comparación entre Líneas de TransMiCable

Las líneas de TransMiCable comparten características estructurales y operativas que justifican su inclusión en el análisis. El Cuadro 4 resume información clave sobre las localidades y barrios afectados, la población beneficiada, la longitud de las líneas y el número de estaciones.

Cuadro 4. Características de las Líneas de TransMiCable en Bogotá (Parte 1). TMS (TransMiCable) y EST (Estación).

Línea TMC	**Localidad Afectada**	**Barrios Afectados**	**N.º Personas Beneficiadas**	**Longitud (km)**	**N.º Est.**
Priemrea Linear	Ciudad Bolívar	Paraíso, Mirador, Juan P II, Manitas	600,000	3.3	4
Potosí	Ciudad Bolívar, Soacha	Altos Cazucá, Potosí, Tres Reyes, Santa Viviana	600,000	3.3	4
San Cristóbal	San Cristóbal	Tunal, La Victoria, Altamira	400,000	2.8	3

Cuadro 4. Características de las Líneas de TransMiCable en Bogotá (Parte 2). TMS (TransMiCable) y EST (Estación).

Línea TMS	**Anuncio**	**Inicio de Construcción**	**Entrega**
Tunal-Paraiso	Noviembre-2015	Septiembre-2016	Diciembre-2018
Potosí	Octubre-2023	2024	2027
San Cristóbal	Marzo-2023	Octubre-2023	2025

La similitud en longitud, número de estaciones y alcance poblacional entre las líneas Tunal-Paraiso y Potosí refuerza su comparabilidad. Esto valida su uso como grupos de

control y tratamiento en el análisis.

5.3. Variación en Distancias y Unidades de Estudio

Para evaluar la sensibilidad de los resultados, se implementan tres ejercicios: variación en las unidades de estudio, en los parámetros de distancia y en los criterios de cercanía. Estos ejercicios examinan la robustez de los resultados frente a diferentes definiciones espaciales.

5.3.1. Variación en la Unidad de Estudio

En este ejercicio, se reemplazan los polígonos iniciales por cuadras como unidad de análisis, lo que incrementa la granularidad y permite capturar dinámicas urbanas con mayor precisión. La Figura 11 muestra la distribución geográfica de las manzanas tratadas bajo diferentes definiciones.

Figura 11. Distribución geográfica de las manzanas bajo diferentes definiciones de tratamiento en las localidades de Ciudad Bolívar y San Cristóbal.

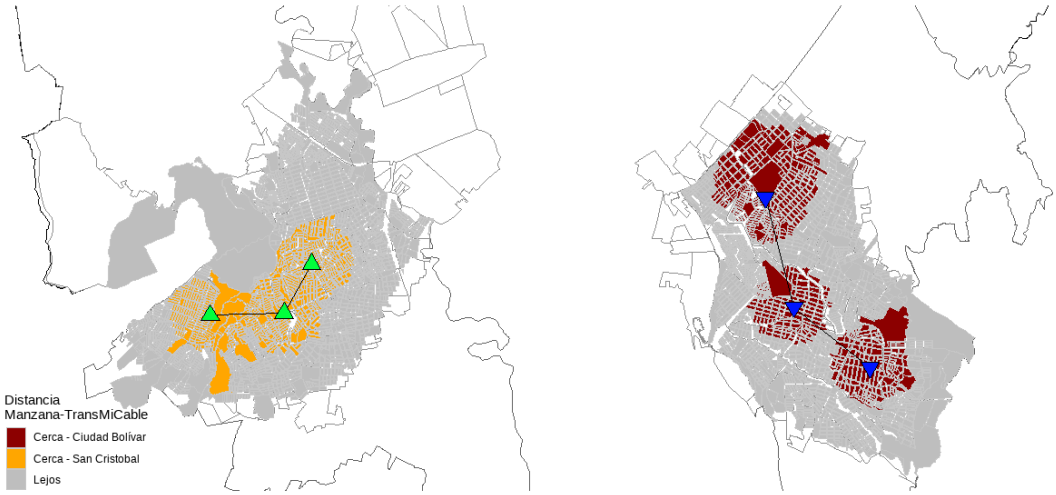

5.3.2. Cambio en Parámetros de Distancia

Este ejercicio varía los umbrales de distancia entre bloques y estaciones, probando valores de 100, 200 y 500 metros entre otros. La Figura 12 ilustra cómo la asignación de bloques tratados y de control cambia bajo estos parámetros, ayudando a identificar efectos de frontera.

Figura 12. Asignación geográfica de bloques tratados y de control bajo diferentes parámetros de distancia al TransMiCable.

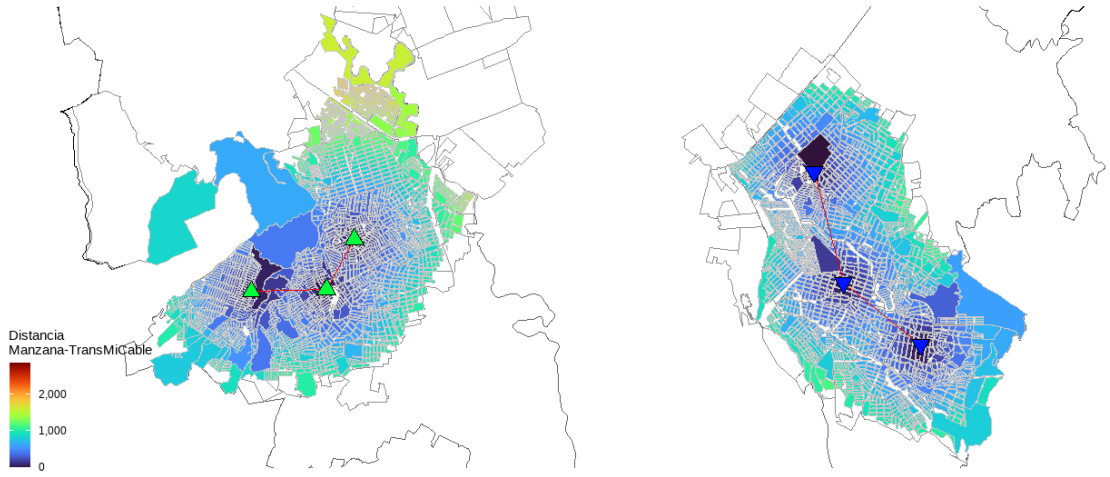

5.3.3. Cambio en Mediciones de Cercanía

Además de las distancias, se evaluaron criterios de cercanía basados en la densidad de número de vecinos cercanos. La Figura 13 presenta la asignación de bloques bajo estas definiciones, destacando interacciones espaciales.

Figura 13. Asignación de bloques tratados y de control utilizando criterios alternativos de vecindad.

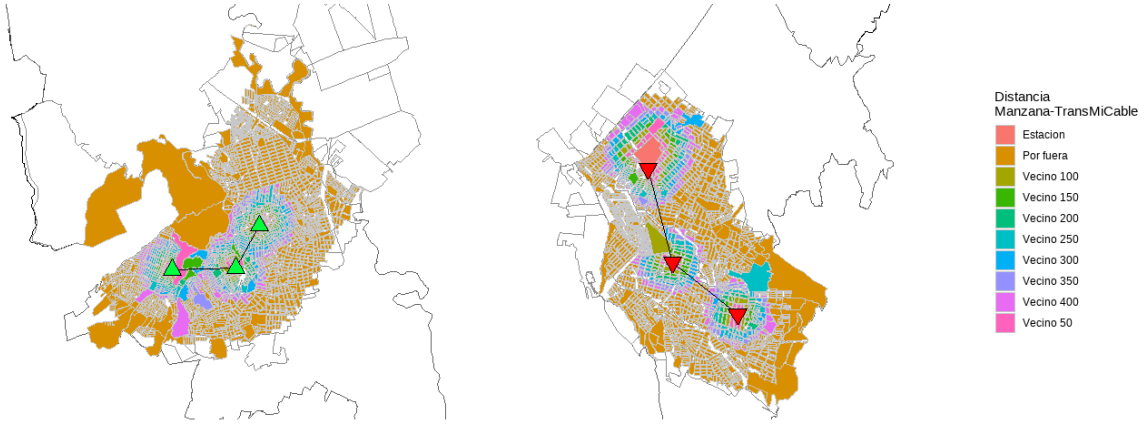

5.4. Discusión sobre Robustez

Los resultados de los ejercicios destacan la importancia de capturar dinámicas urbanas a diferentes niveles de agregación y de evaluar efectos espaciales. La combinación de análisis con distintas unidades, distancias y criterios de cercanía asegura que las conclusiones sean robustas y no dependan de un conjunto específico de supuestos metodológicos. Este enfoque sigue las recomendaciones de Rosenbaum and Rubin (1983) para validar diseños observacionales en contextos urbanos densamente conectados.

6. Conclusión

Este estudio analiza el impacto preliminar del TransMiCable en la densidad urbana y la ocupación de terrenos en áreas vulnerables, utilizando un enfoque econométrico basado en diferencias en diferencias y matching. Los resultados iniciales indican un efecto positivo en la expansión urbana en las zonas tratadas, sugiriendo que esta infraestructura mejora la accesibilidad y genera incentivos para el desarrollo urbano. Sin embargo, las limitaciones actuales en la calidad de los datos, especialmente en localidades como Soacha, exigen cautela al interpretar estos hallazgos.

El análisis identifica patrones consistentes con las hipótesis iniciales, particularmente en la expansión hacia terrenos previamente no desarrollados y áreas de riesgo geográfico. No obstante, se reconoce que este trabajo se encuentra en una etapa preliminar y que persisten desafíos metodológicos, como la necesidad de mejorar los modelos de conteo y realizar validaciones cruzadas con fuentes alternativas. Estos pasos son fundamentales para garantizar la precisión y robustez de los resultados.

En su estado actual, este trabajo proporciona indicios iniciales que respaldan la relación entre la infraestructura de transporte y el desarrollo urbano, pero también subraya la importancia de abordar las limitaciones de los datos y la metodología. A medida que se avanza en la refinación del análisis, se espera generar resultados más concluyentes que contribuyan a la comprensión del impacto del TransMiCable y ofrezcan implicaciones relevantes para la planeación urbana en contextos vulnerables.

7. Figuras:

En esta sección se incluyen Cuadros y figuras complementarias, que por su tamaño o contenido secundario no fueron incorporadas directamente en el cuerpo principal del documento.

Figura 1. Aumento densidad en zonas cercanas a la creación de TransMiCable en ciudad bolivar estación Mirador. Marca roja Zona de enfoque, marca amarilla estacion.

(a) Imágen satelital de Google Earth Pro, 2013. Polígono no divulgable, Ciudad Bolívar, Bogotá.

(b) Imágen satelital de Google Earth Pro, 2016. Polígono no divulgable, Ciudad Bolívar, Bogotá.

(c) Imágen satelital de Google Earth Pro, 2018. Polígono no divulgable, Ciudad Bolívar, Bogotá.

(d) Imágen satelital de Google Earth Pro, 2020. Polígono no divulgable, Ciudad Bolívar, Bogotá.

Figura 2. Aparición de nuevas comunidades cercanas a la construcción del TransMiCable, estación Juan Pablo Segundo. Marca roja Zona de enfoque, marca amarilla estacion tranmicable.

(a) Imágen satelital de Google Earth Pro, 2014. Polígono no divulgable, Ciudad Bolívar, Bogotá.

(b) Imágen satelital de Google Earth Pro, 2016. Polígono no divulgable, Ciudad Bolívar, Bogotá.

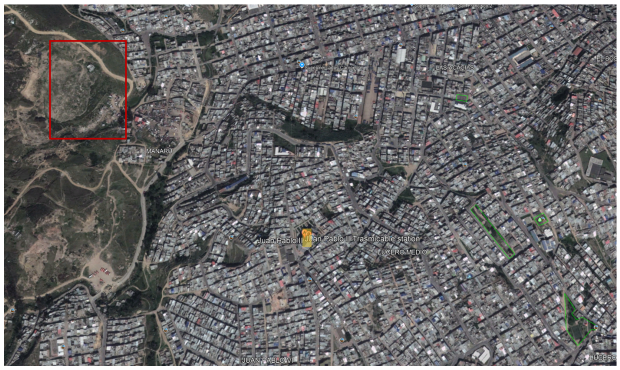

(c) Imágen satelital de Google Earth Pro, 2018. Polígono no divulgable, Ciudad Bolívar, Bogotá.

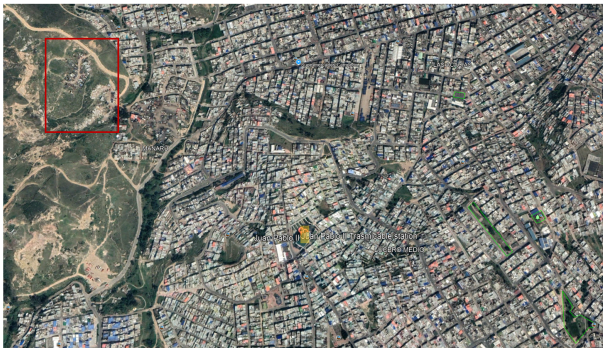

(d) Imágen satelital de Google Earth Pro, 2020. Polígono no divulgable, Ciudad Bolívar, Bogotá.

Figura 3. Desplazamiento a zonas de alto riesgo geográfico en Ciudad Bolívar

(a) Imágen satelital de Google Earth Pro, 2018. Polígono no divulgable, Ciudad Bolívar, Bogotá. Zona de Riesgo geografico [a]

[a]Zonas con inclinaciones de mas del 30 % segun las plancahas cartograficas del IGAC

(b) Imágen satelital de Google Earth Pro, 2021. Polígono no divulgable, Ciudad Bolívar, Bogotá. Zona de Riesgo geografico [a]

[a]Zonas con inclinaciones de mas del 30 % segun las plancahas cartograficas del IGAC

Figura 4. Mapa de sub polígonos de Ciudad Bolívar (en azul), San Cristóbal (en verde) y Soacha (Rojo).

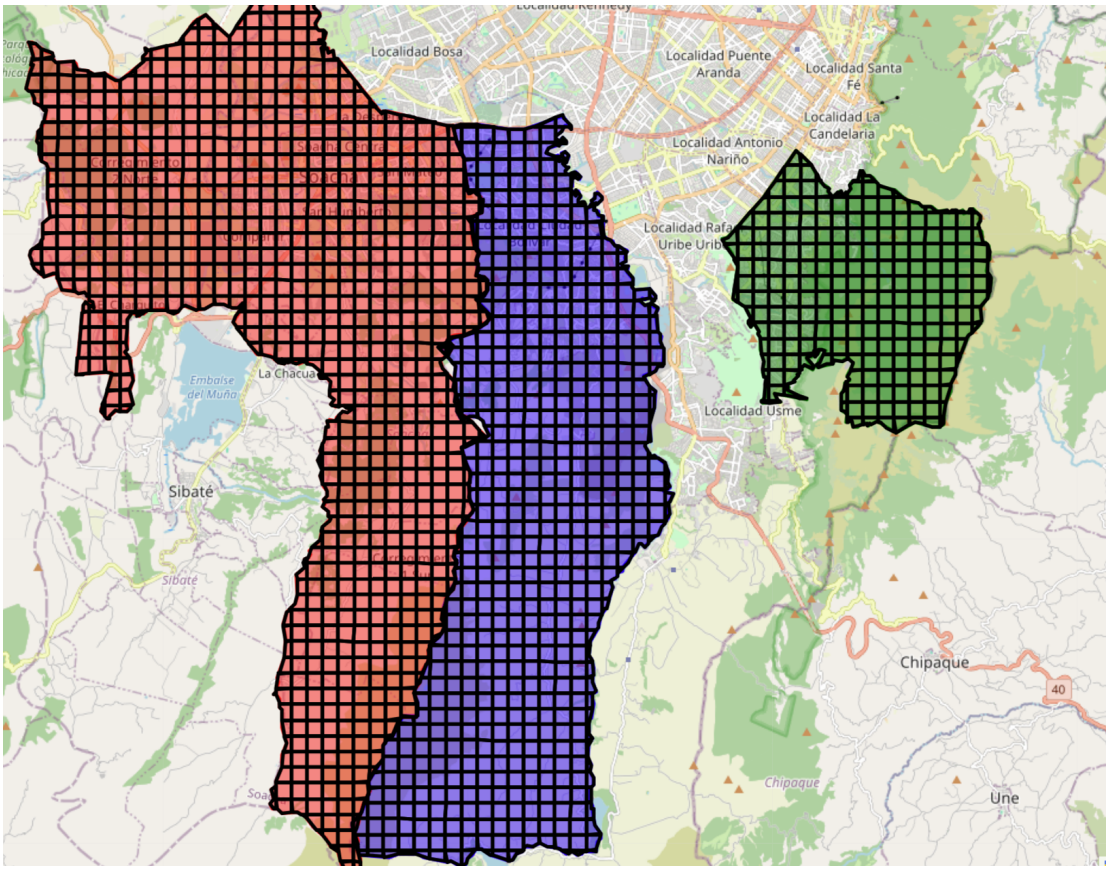

Figura 5. Esquema del flujo de creación y procesamiento de datos. Este diagrama representa las etapas clave en el procesamiento de información geoespacial. Primero, las **Fuentes de Información** incluyen datos descargados de la API de polígonos de Bogotá, *Google Earth Engine*, y el portal de Datos Abiertos. A continuación, en la etapa de **Procesamiento**, se utilizan scripts en *Python* para: (1) procesar polígonos de localidades; (2) extraer imágenes de satélite automáticamente mediante conexión a *Google Earth Engine*; (3) derivar características geográficas relevantes de las placas geográficas, y (4) realizar conteos de edificios y extracción de características utilizando modelos de *Machine Learning*. Finalmente, los datos generados son almacenados en una **Base de Datos** que incluye bloques, imágenes, mapas, características y etiquetas, garantizando una estructura lista para el análisis.

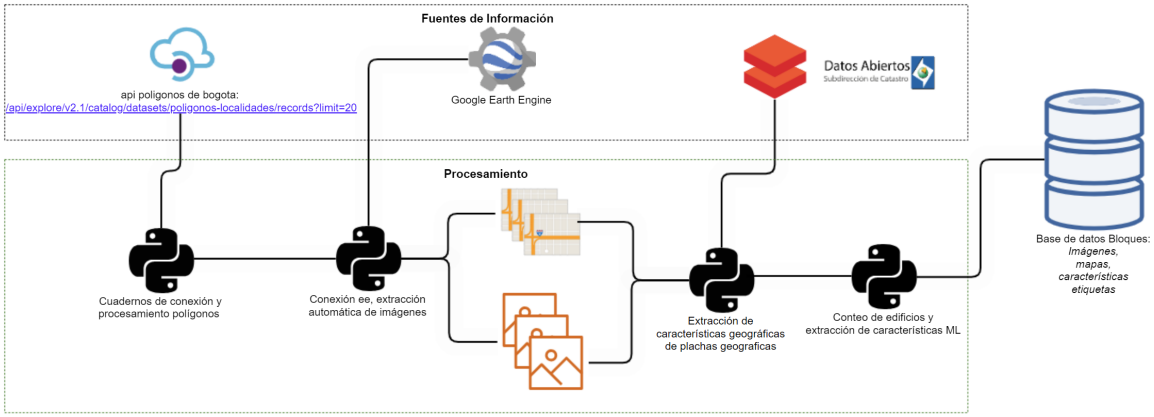

Figura 6. Integración de planchas IGAC con imágenes satelitales: Ejemplo gráfico de la superposición de capas geoespaciales.

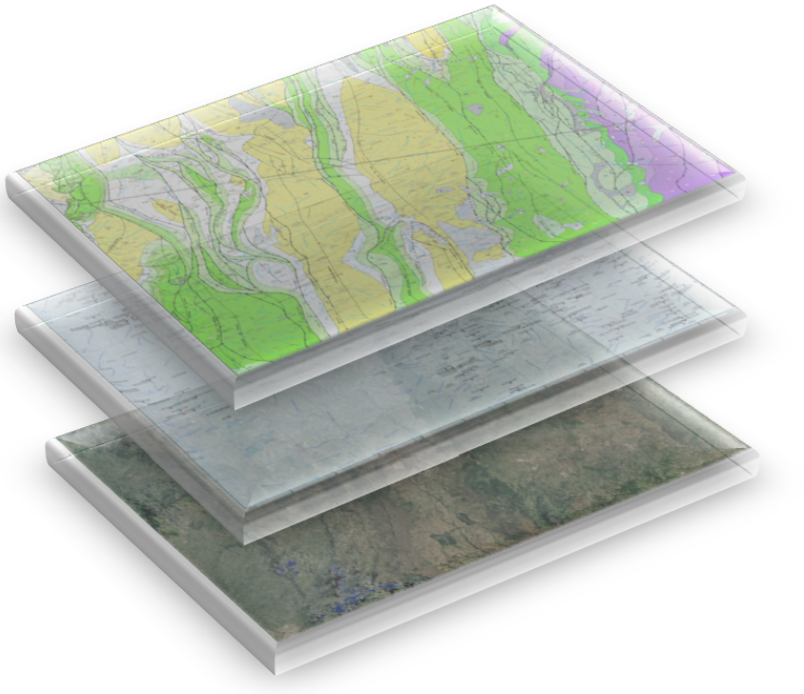

Figura 7. Ejemplo de uso de el modelo SAM en la base de datos Poligono confidencias Ciudad Bolivar.

Figura 8. Ejemplo de uso de el modelo SAM en la base de datos Poligono confidencias Soacha.

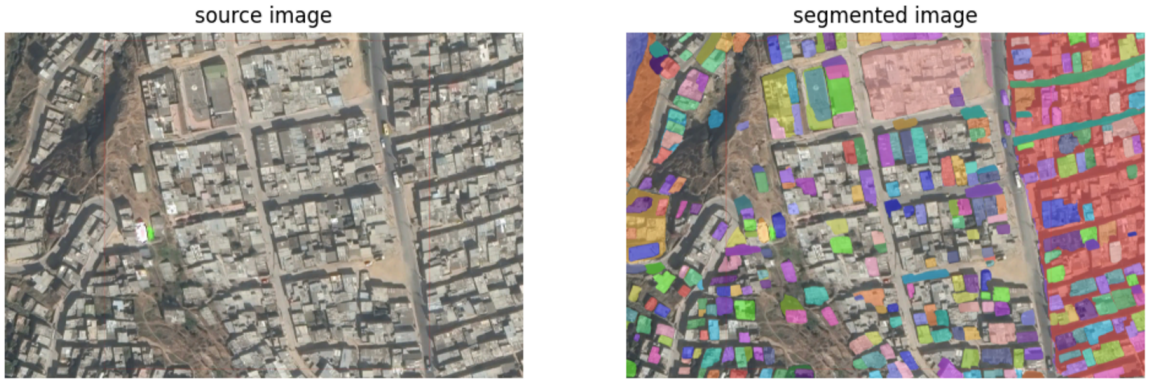

Figura 9. Ejemplo de uso del modelo de identificación de edificios en la localidad de Ciudad Bolívar.

(a) Identificación del polígono a evaluar.

(b) Resultado del modelo en la identificación de edificios. En rojo, estructuras con poca confianza; en amarillo, confianza media; y en verde, confianza alta.

Referencias

Alcaldía Bogotá (2023). Transmicable: Impacto y cobertura en ciudad bolívar y san cristóbal. Consultado el 1 de diciembre de 2024.

Alcaldía Mayor de Bogotá (2023). Avances de infraestructura del transmicable: Reporte de progreso 2023. Informe oficial.

Alcaldía Municipal de Soacha (2017). Plan de ordenamiento territorial de soacha 2017. Accedido: 2024-12-02.

Angrist, J. D. and Pischke, J.-S. (2008). *Mostly Harmless Econometrics: An Empiricist's Companion*. Princeton University Press, Princeton, NJ.

Arribas-Bel, D., Garcia-López, M.-À., and Viladecans-Marsal, E. (2021). Building (s and) cities: Delineating urban areas with a machine learning algorithm. *Journal of Urban Economics*, 125:103217.

Aytekin, C. and Uysal, M. (2018). Deep feature learning for satellite imagery using cnns. *International Journal of Remote Sensing*.

Bowles, S., Durlauf, S. N., and Hoff, K. (2006). Poverty traps. *Princeton University Press*.

Brand, P. and Dávila, J. D. (2011). Mobility innovation at the urban margins: Medellín's metrocable. *City*, 15(6):647–661.

Butts, K. (2024). Interference and spillovers in social networks: New methods. *Social Science Methodology Review*.

Contraloría Distrital de Bogotá (2022). Informe técnico de avance del transmicable. Informe técnico oficial.

Departamento Administrativo Nacional de Estadística (DANE) (2018). Proyecciones de población bogotá 2018-2035. Accedido: 2024-12-02.

Duranton, G. and Turner, M. A. (2012). Urban growth and transportation. *Review of Economic Studies*, 79(4):1407–1440.

Dávila, J. D. (2013). *Urban mobility and poverty: Lessons from Medellín and Soacha, Colombia*. UCL.

Everingham, M., Van Gool, L., Williams, C. K., et al. (2015). The pascal visual object classes (voc) challenge. *International journal of computer vision*, 111(1):98–136.

Gibbons, S., Overman, H. G., and Resende, G. (2012). The causal impact of transport investments on firm performance: Evidence from the opening of the uk motorway network. *Journal of Urban Economics*, 74:14–31.

Google (2021). Open buildings v3 polygons. https://sites.research.google/open-buildings/.

Gorelick, N., Hancher, M., Dixon, M., Ilyushchenko, S., Thau, D., and Moore, R. (2017). Google earth engine: Planetary-scale geospatial analysis for everyone. *Remote sensing of Environment*, 202:18–27.

Hirano, K., Imbens, G. W., and Ridder, G. (2003). Efficient estimation of average treatment effects using the estimated propensity score. *Econometrica*, 71(4):1161–1189.

Iatrou, A., Nikitidis, A., and Athanasiou, D. (2021). U-net architectures for building footprint extraction from satellite images. *Remote Sensing*, 13(5):1098.

Imbens, G. W. and Rubin, D. B. (2015). *Causal Inference for Statistics, Social, and Biomedical Sciences: An Introduction*. Cambridge University Press.

Instituto de Desarrollo Urbano (IDU) (2020). Actualización, ajustes y complementación de la factibilidad y los estudios y diseños del cable aéreo en san cristóbal, bogotá d.c. Contrato de Consultoría No. 1630.

Instituto Geográfico Agustín Codazzi (2020). *Cartografía Geomorfológica Aplicada a Estudios de Suelos*.

Kirillov, A., Mintun, E., Ravi, N., et al. (2023). Segment anything. *arXiv preprint arXiv:2304.02643*.

Krishna, A. (2010). Escaping poverty and becoming poor: Who gains, who loses, and why? *World Development*, 32(1):121–136.

Krizhevsky, A., Sutskever, I., and Hinton, G. E. (2012). Imagenet classification with deep convolutional neural networks. *Communications of the ACM*, 60(6):84–90.

LeCun, Y., Bengio, Y., and Hinton, G. (2015). Deep learning. *Nature*, 521(7553):436–444.

Li, X. (2021). Counting buildings from satellite images using deep learning. *Remote Sensing of Environment*.

OpenDataSoft (2024). Api de polígonos de localidades de bogotá. https://bogota-laburbano.opendatasoft.com/api/explore/v2.1/catalog/datasets/poligonos-localidades/records?limit=20. [API].

Pollman, M. (2022). Causal inference with spatial spillovers. *Journal of Spatial Econometrics*.

Ronneberger, O., Fischer, P., and Brox, T. (2015). U-net: Convolutional networks for biomedical image segmentation. In Navab, N., Hornegger, J., Wells, W. M., and Frangi,

A. F., editors, *Medical Image Computing and Computer-Assisted Intervention – MICCAI 2015*, volume 9351 of *Lecture Notes in Computer Science*, pages 234–241. Springer International Publishing.

Rosenbaum, P. and Rubin, D. (1983). The central role of the propensity score in observational studies for causal effects. *Biometrika*.

Roy, D. P., Wulder, M. A., Loveland, T. R., Woodcock, C. E., Allen, R. G., Anderson, M. C., Helder, D., Irons, J. R., Johnson, D. M., Kennedy, R., et al. (2014). Landsat-8: Science and product vision for terrestrial global change research. *Remote Sensing of Environment*, 145:154–172.

Shah, V., Martin, C., and Jain, P. (2018). Fine-resolution mapping of urban structure and dynamics using street view imagery. *Scientific data*, 5:180139.

Technologies, M. (2020). Worldview-3 and worldview-4 data.

Tiempo, E. (2023). Nueva línea de transmicable en potosí beneficiará a 600.000 personas. Consultado el 1 de diciembre de 2024.

Toutin, T. (2004). Geometric processing of remote sensing images: Models, algorithms and methods. *International Journal of Remote Sensing*, 25(10):1893–1924.

Vasquez-Bare, G. (2022). Spillovers and sutva violations in causal inference. *Journal of Causal Inference*.

Volpi, M. and Tuia, D. (2016). Feature extraction from satellite imagery with deep learning. *IEEE Transactions on Geoscience and Remote Sensing*.

Wulder, M. A., Masek, J. G., Cohen, W. B., Loveland, T. R., and Woodcock, C. E. (2012). Opening the archive: How free data of landsat changed the science and society. *Remote Sensing of Environment*, 122:2–10.

Zhu, Z. and Woodcock, C. E. (2014). Continuous change detection and classification of land cover using all available landsat data. *Remote sensing of environment*, 144:152–171.